


量子機械学習

Sep 30, 2025

沼田 祈史
Kifumi Numata
IBM Quantum



昨日の補足

ベクトル・行列演算

- ベクトルとベクトルの**テンソル積**：左側のベクトルの成分に右側のベクトルをかける。

$$\begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} \otimes \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} v_1 \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix} \\ \vdots \\ v_n \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix} \end{pmatrix}$$

- 行列と行列の**テンソル積**：左側の行列の成分に右側の行列をかける。

$$A \otimes B = \begin{pmatrix} A_{11}B & A_{12}B \\ A_{21}B & A_{22}B \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} A_{11}B_{11} & A_{11}B_{12} \\ A_{11}B_{21} & A_{11}B_{22} \end{pmatrix} & \begin{pmatrix} A_{12}B_{11} & A_{12}B_{12} \\ A_{12}B_{21} & A_{12}B_{22} \end{pmatrix} \\ \begin{pmatrix} A_{21}B_{11} & A_{21}B_{12} \\ A_{21}B_{21} & A_{21}B_{22} \end{pmatrix} & \begin{pmatrix} A_{22}B_{11} & A_{22}B_{12} \\ A_{22}B_{21} & A_{22}B_{22} \end{pmatrix} \end{pmatrix}$$

- 2量子ビットの状態は、1量子ビットのテンソル積で表せます

$$\begin{aligned} |00\rangle &= |0\rangle \otimes |0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \otimes \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} = |0\rangle, & |01\rangle &= |0\rangle \otimes |1\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \otimes \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} = |1\rangle, \\ |10\rangle &= |1\rangle \otimes |0\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \otimes \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix} = |2\rangle, & |11\rangle &= |1\rangle \otimes |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \otimes \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} = |3\rangle \end{aligned}$$

量子テレポーテーションアルゴリズムの詳細

Qiskitではビットの並びが|q2 q1 q0>です

$$|\psi_0\rangle = |00\rangle \otimes (\alpha|0\rangle + \beta|1\rangle)$$

Aliceの持っている暗号

$$|\psi_1\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle) \otimes (\alpha|0\rangle + \beta|1\rangle)$$

エンタングルメント

$$= \frac{1}{\sqrt{2}}(\alpha|000\rangle + \alpha|110\rangle + \beta|001\rangle + \beta|111\rangle)$$

$$|\psi_2\rangle = \frac{1}{\sqrt{2}}(\alpha|000\rangle + \alpha|110\rangle + \beta|011\rangle + \beta|101\rangle)$$

q0が1の時のみq1にXを操作

$$= \frac{1}{\sqrt{2}}(\alpha(|00\rangle + |11\rangle)|0\rangle + \beta(|01\rangle + |10\rangle)|1\rangle)$$

aとβでまとめる

$$|\psi_3\rangle = \frac{1}{2}(\alpha(|00\rangle + |11\rangle)(|0\rangle + |1\rangle) + \beta(|01\rangle + |10\rangle)(|0\rangle - |1\rangle))$$

q0にHを操作


$$= \frac{1}{2}((\alpha|0\rangle + \beta|1\rangle)|00\rangle + (\alpha|1\rangle + \beta|0\rangle)|10\rangle + (\alpha|0\rangle - \beta|1\rangle)|01\rangle + (\alpha|1\rangle - \beta|0\rangle)|11\rangle)$$

q2にそのまま暗号が
現れている

q1が1の時は
q2にXゲートをかける

q0が1の時は
q2にZゲートをかける

q0とq1が1の時は
q2にXゲートとZゲートをかける





NETFLIX

ホーム TV番組・ドラマ 映画 新作&人気作 マイリスト 言語別に検索



mamaさんにイチオシ!




あなたにピッタリのオススメ作品





ChatGPT ▾

✦ Plus をはじめる



今日は何をしましょうか？


質問してみましょう

+ 🛠 ツール



機械学習

教師あり学習



猫や犬の写真がラベル付けされた集合から、新しい猫や犬の写真を識別する。

教師なし学習



映画の視聴履歴に基づいて視聴者をグループ分けし、新しい映画を推薦する。

強化学習




囲碁のプレイ方法をアルゴリズムで学習する。

生成系AIは、これらを組みわせて学習しています。

機械学習


教師あり学習



ラベル付きデータ (x_i, y_i) :
マッピングする関数 $y = f(x)$ を
学習。

猫や犬の写真がラベル付け
された集合から、新しい猫
や犬の写真を識別する。


教師なし学習



ラベルのないデータ :
何らかの構造を学習。

映画の視聴履歴に基づいて視聴
者をグループ分けし、新しい映
画を推薦する。

強化学習




行動に応じて報酬が得られる環
境で、期待される報酬を最大
化。

囲碁のプレイ方法をアルゴリズム
で学習する。

機械学習


教師あり学習



ラベル付きデータ (x_i, y_i) :
マッピングする関数 $y = f(x)$ を
学習。

例) 猫や犬の写真がラベル付けされた
集合から、新しい猫や犬の写真を識別す
る。


教師なし学習



ラベルのないデータ :
何らかの構造を学習。

例) 映画の視聴履歴に基づいて視聴者を
グループ分けし、新しい映画を推薦す
る。


強化学習




行動に応じて報酬が得られる環境
で、期待される報酬を最大化。

例) 「パックマン」のプレイ方法をアル
ゴリズムで学習する。



イチゴとリンゴをどうやってコンピューターは見分けるのでしょうか？





特徴をもとに判別しています。
イチゴとリンゴを区別する特徴は何でしょう？





イチゴとリンゴ



どちらの方がよく分類できているでしょうか？



右図の方が境界線と最も近いデータ点との距離が長い




より安定した分け方


SVM(サポートベクターマシン) とは

データを2つのグループに分ける手法(2値分類)

- グループ間の境界面を定める分析手法
- マージン（境界線と最近接データ点との距離）をできるだけ大きく取るように最適化




直線で分けられないデータの場合




このようなデータセットは、
2グループに分けられることは
明らかですが、
境界線が直線にはなりません。
(線形に分離できないといいます)

データマッピングで分類




3次元では、データは平面で
分離できる





特徴量を高次元化(特徴量マッピング)することで、
平らな(線形な)境界面で切り分けることができます。

量子SVM(サポートベクターマシン)

特徴量を量子空間に特徴量マッピングすることで、線形な境界面で切り分けます。



量子状態の球に
マッピング



データを量子機械学習のために符号化する手法（代表的なもの）

1. 計算基底符号化
2. 振幅符号化
3. 角度符号化
4. 角度符号化の応用


データを量子機械学習のために符号化する手法（代表的なもの）

1. 計算基底符号化

古典的な N ビット文字列を N 量子ビットの**計算基底状態**に符号化します。

(*) **計算基底状態**：Z基底状態とも呼ばれ、Z（または計算）基底で測定したときの状態。
 $|00\rangle$ や $|00110100\rangle$ のようなラベルを持つ状態です。IBMのシステムは常にZ基底で測定します。

例) データセット $X = \{x_1 = 101, x_2 = 111\}$ ➡ 量子状態 $|x\rangle = \frac{1}{\sqrt{2}}(|101\rangle + |111\rangle)$




データを量子機械学習のために符号化する手法（代表的なもの）

2. 振幅符号化

データを量子状態の振幅に符号化。
（計算基底が余る場合は、振幅をゼロにします。）

例) $X = \{x_1 = (1.5, 0), \quad x_2 = (-2, 3)\}$ \rightarrow $|x\rangle = \frac{1}{\sqrt{15.25}} (1.5|00\rangle - 2|10\rangle + 3|11\rangle)$


量子状態





データを量子機械学習のために符号化する手法（代表的なもの）

3. 角度符号化

角度符号化は、RX ゲートまたは RY ゲートなどの回転ゲートの角度にデータを符号化。

例) データポイント $x = (x_1, x_2)$  $S_x = RY(x_1) \otimes RY(x_2)$



データを量子機械学習のために符号化する手法（代表的なもの）


4. 角度符号化の応用

角度符号化を応用し、位相にデータを代入。さらに任意のユニタリー演算（CNOTなど）を含む。
複数のデータを1量子ビットに符号化することも可能。


例) $x = (x_1, x_2)$



$$S_x = P(x_2)RY(x_1)$$




例) $x = (x_1, \dots, x_8)$



2 量子ビットだけで 8 つのデータを符号化

量子状態の位相とは

ブロッホ球



任意の量子ビットの量子状態： $|\psi\rangle = \alpha |0\rangle + \beta |1\rangle$

ここで、 α, β は $|\alpha|^2 + |\beta|^2 = 1$ を満たす複素数。

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right) |0\rangle + \exp(i\varphi) \sin\left(\frac{\theta}{2}\right) |1\rangle \cdots (\star)$$

位相(Phase)

量子状態の複素数の角度が位相。

R_z ゲートの角度に相当するので、 R_z ゲートをPhase ゲートとも呼ぶ。

一般的に直行座標 (x, y, z) と極座標 (r, θ, φ) は、

$$\begin{aligned} |\psi\rangle &= z|0\rangle + (x + iy) |1\rangle \\ &= \cos\theta |0\rangle + (\sin\theta \cos\varphi + i \sin\theta \sin\varphi) |1\rangle \end{aligned}$$


ですが、これでは、 $\theta = 0^\circ$ で $|0\rangle$ 、 $\theta = 90^\circ$ で $|1\rangle$ になり、上半球の領域しか覆わないので、 $\theta = 0^\circ$ で $|0\rangle$ 、 $\theta = 180^\circ$ で $|1\rangle$ となるように、 $\theta' = 2\theta$ とする。

θ' を θ と書くと (\star) の式になる。

データを量子機械学習のために符号化する手法（代表的なもの）


1. 計算基底符号化

例) データセット $X = \{x_1 = 101, x_2 = 111\}$ \rightarrow 量子状態 $|x\rangle = \frac{1}{\sqrt{2}}(|101\rangle + |111\rangle)$



2. 振幅符号化

例) $X = \{x_1 = (1.5, 0), x_2 = (-2, 3)\}$ \rightarrow $|x\rangle = \frac{1}{\sqrt{15.25}}(1.5|00\rangle - 2|10\rangle + 3|11\rangle)$





3. 角度符号化

例) データポイント $x = (x_1, x_2)$ \rightarrow $S_x = RY(x_1) \otimes RY(x_2)$



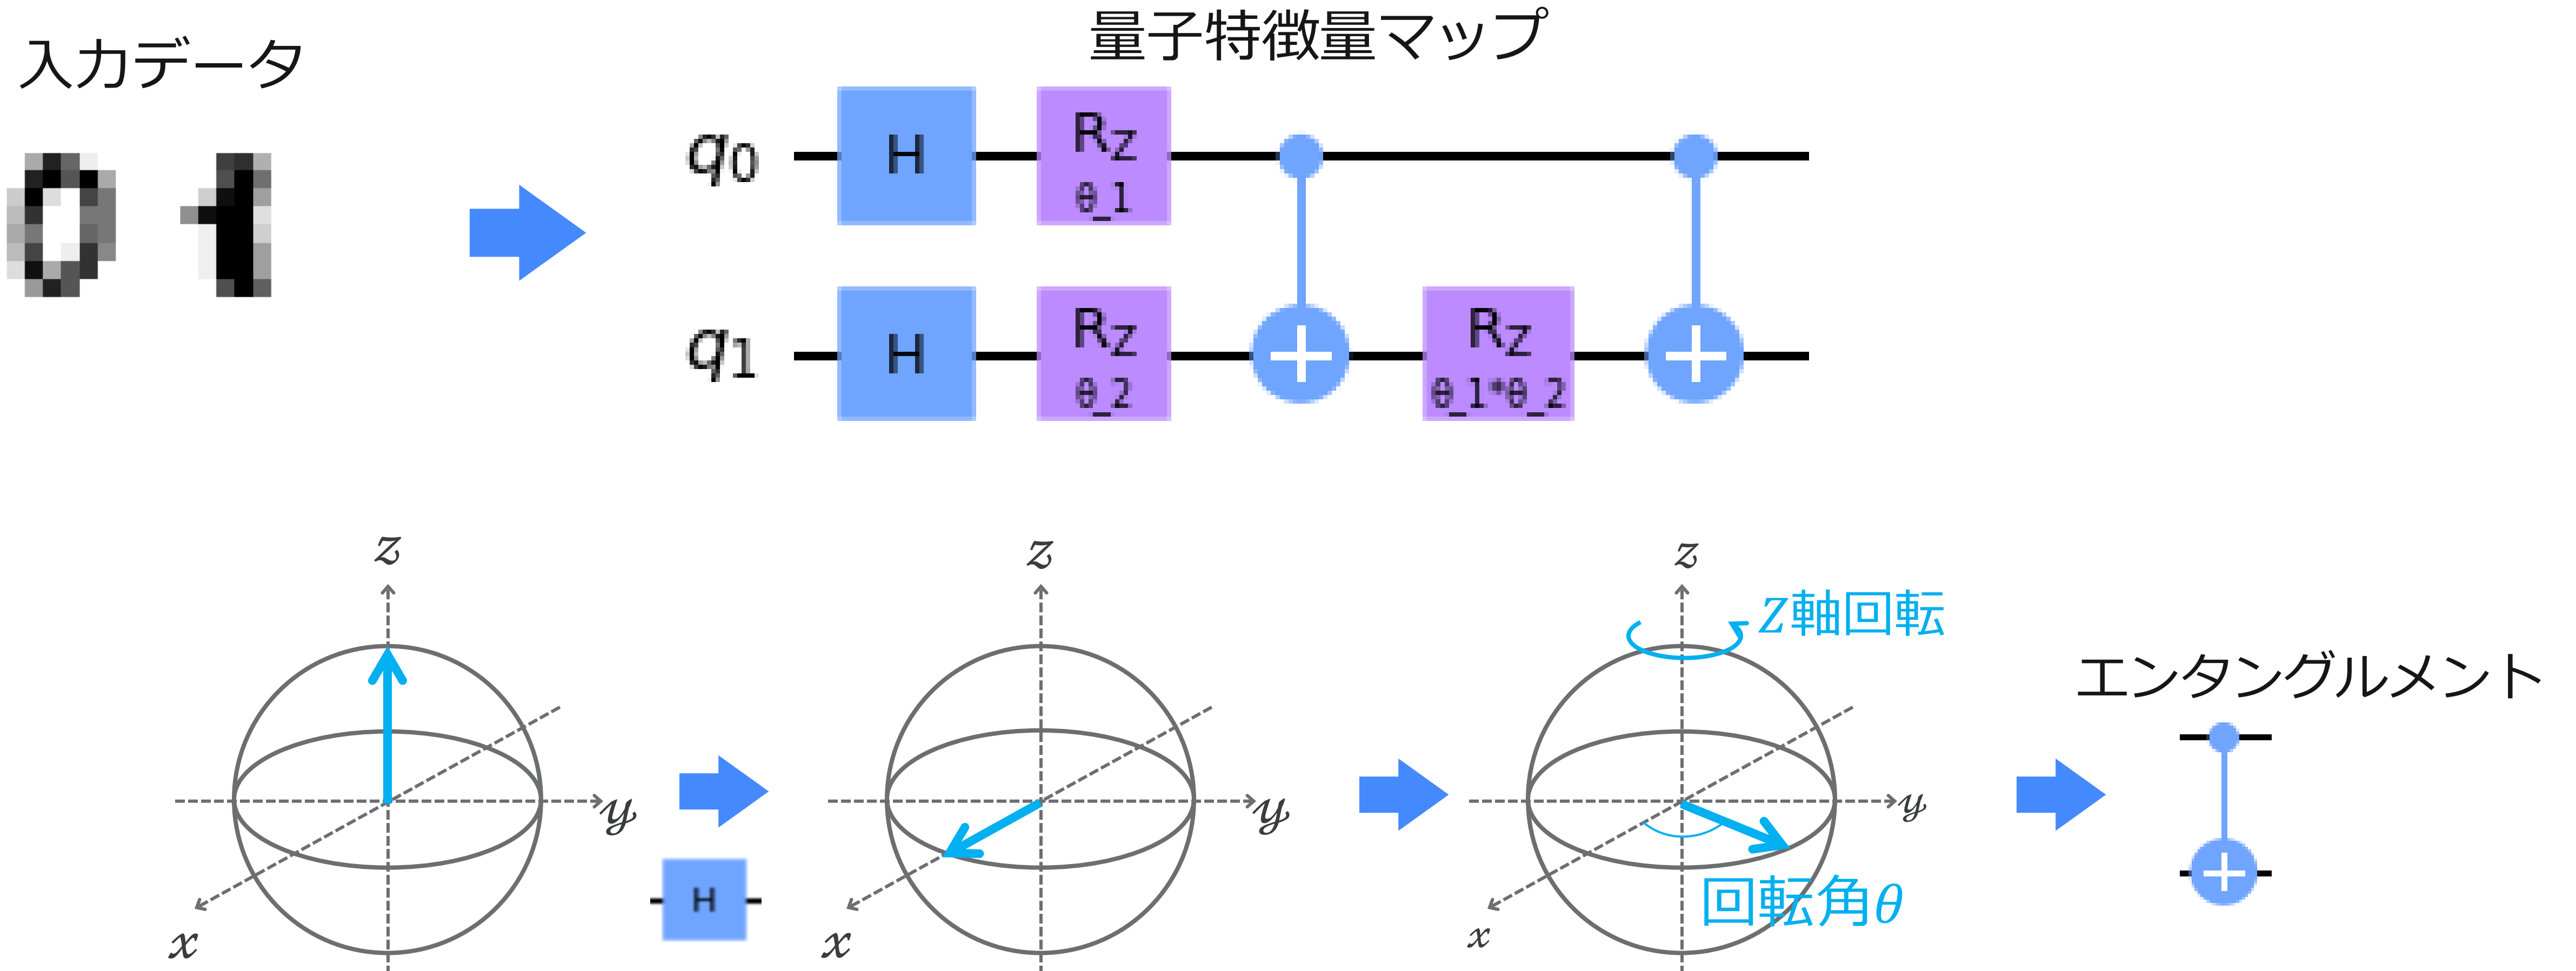
4. 角度符号化の応用

例) $x = (x_1, x_2)$



量子特徴量マップ (Feature Map)


データを量子データにエンコード（符号化）する際に、
パラメーター（量子ゲートの回転角 θ ）を使った、角度符号化の応用の
量子特徴量マップ (Feature Map)を使って、回転角 θ の部分にデータを入れます。



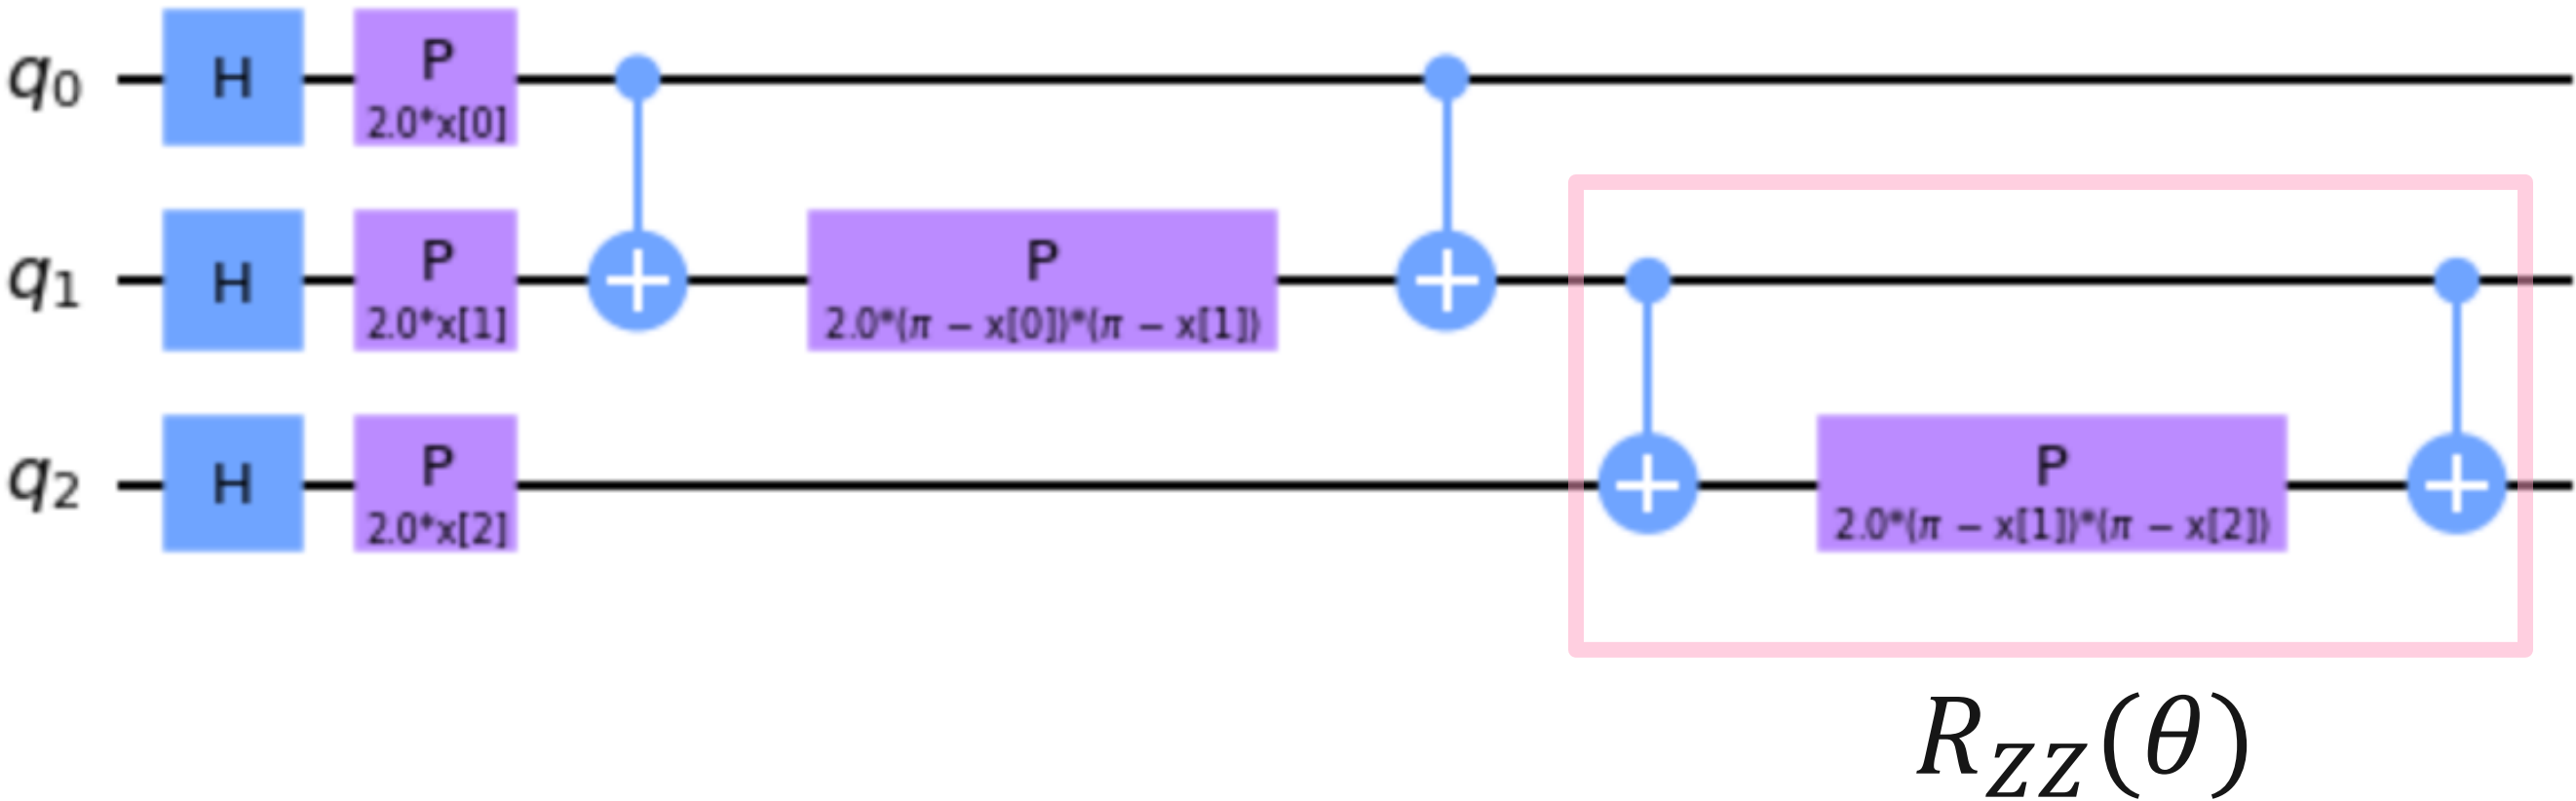
量子特徴量マップの例

データ x が3次元の場合

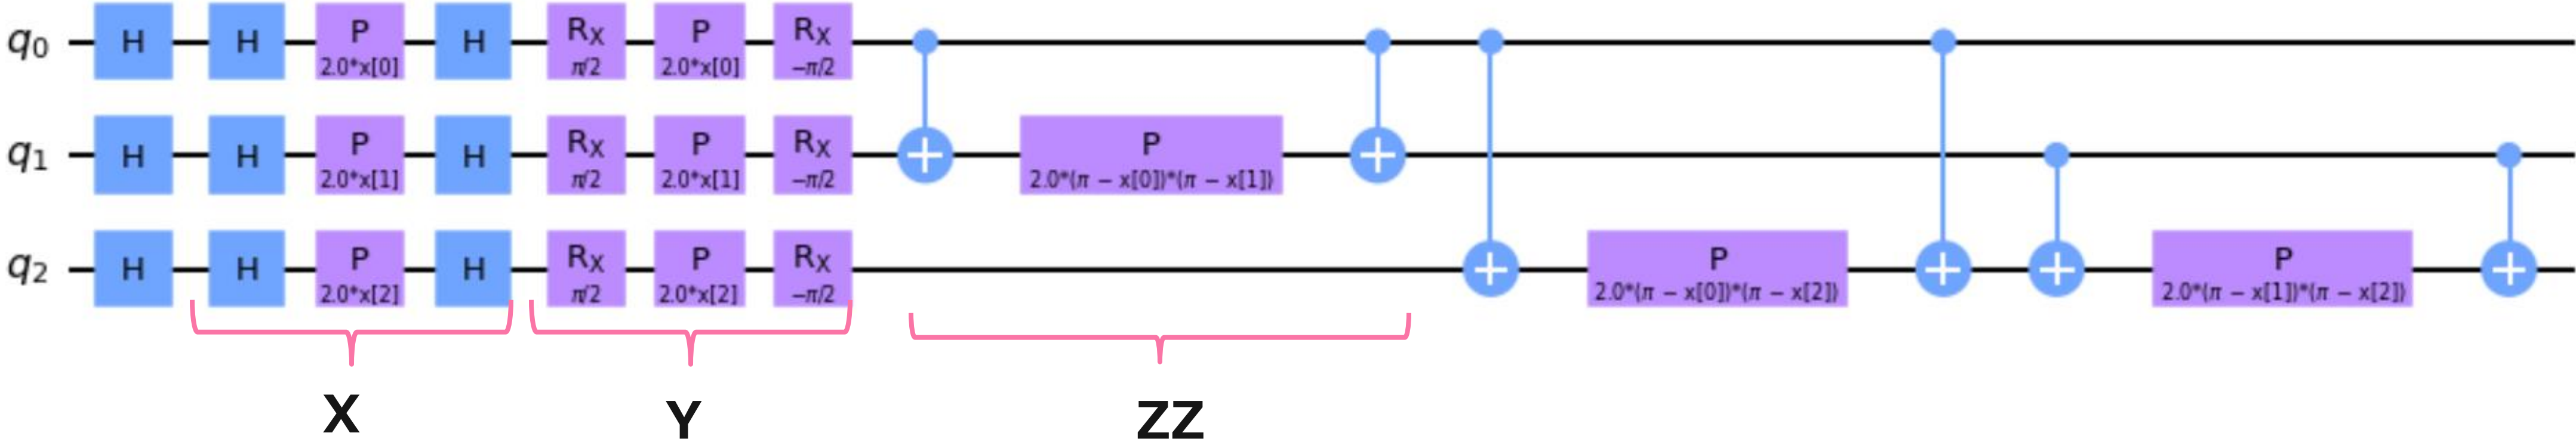
Z feature map



ZZ feature map



Pauli feature map (X, Y, ZZの場合)




等価回路

$$X = HZH$$
$$Y = R_X(\pi/2)Z R_X(-\pi/2)$$


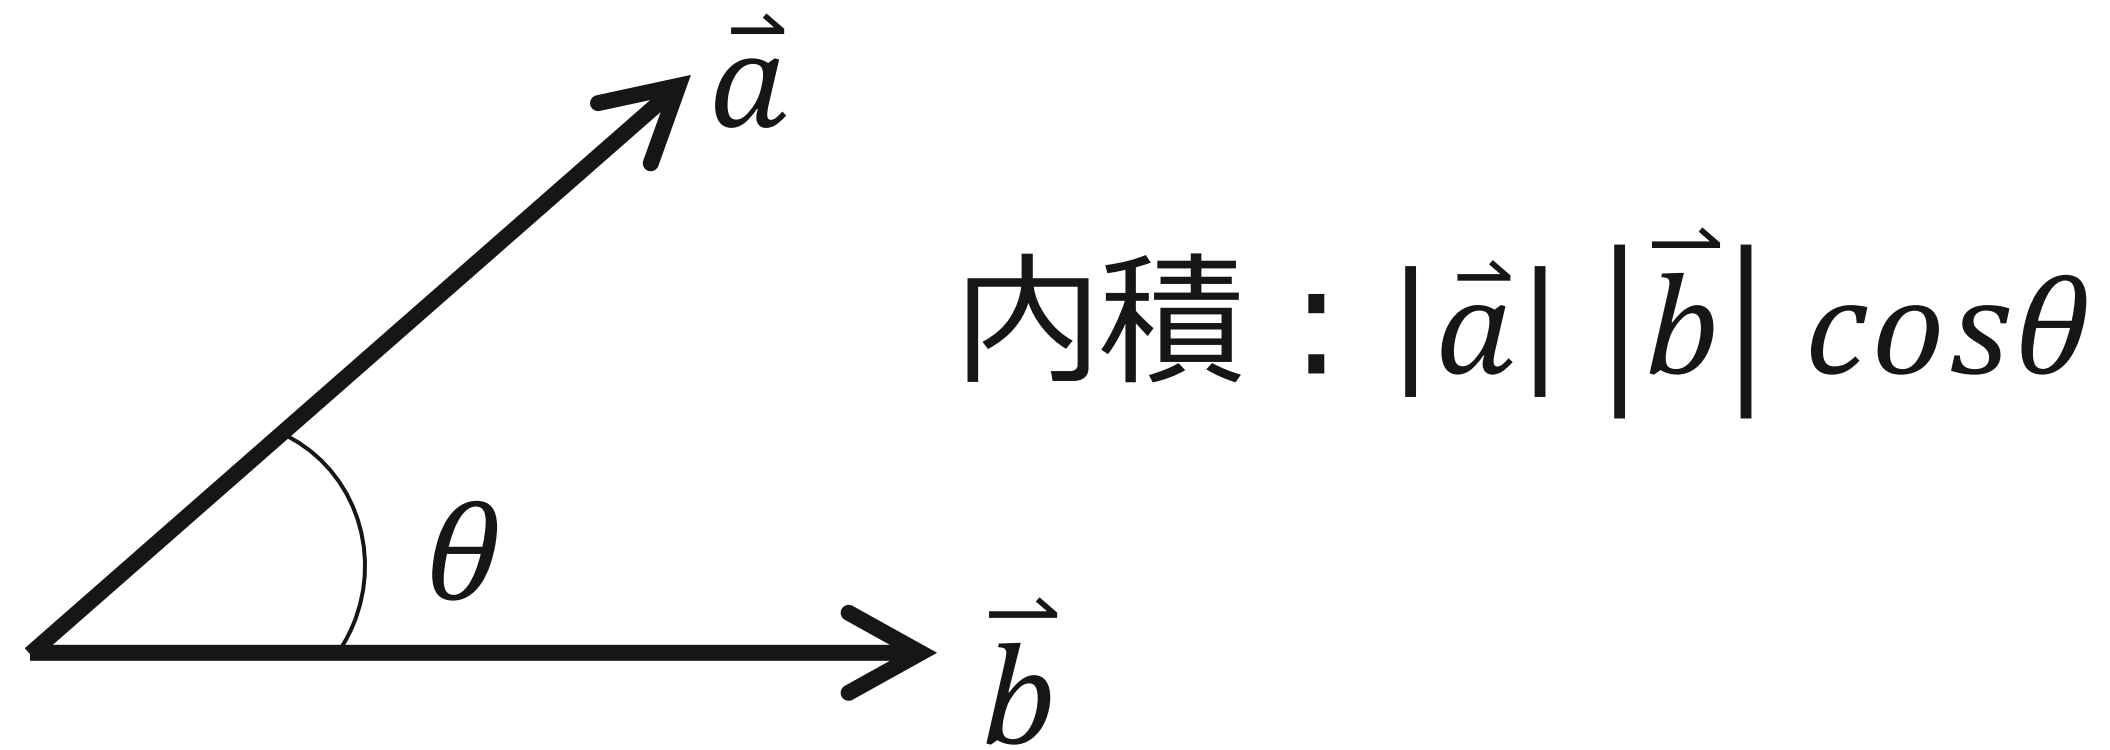
量子カーネルSVM

データを量子特徴量マップ(Feature Map)でエンコードした後、



量子回路で量子カーネル(類似度)の計算を行い、
量子カーネルを使って、古典SVM計算(線形な境界面で分ける2値分類)で学習・分類を行います。

カーネル(類似度)計算は、ベクトルの内積の発展形






直行した
ベクトルの
内積は0



自分自身との
内積は1

カーネル(類似度)行列



全く違う特徴：0(白)
同じ特徴：1(濃紺/赤)

ブラケット表記

量子状態： $|\psi\rangle = \alpha |0\rangle + \beta |1\rangle$

(ここで、 α, β は $|\alpha|^2 + |\beta|^2 = 1$ を満たす複素数。)

ケット

$|\psi\rangle = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}$: 縦ベクトル

ブラ

$\langle\psi| = (|\psi\rangle)^\dagger = (\alpha^* \quad \beta^*)$: 横ベクトル

ベクトル $\langle\psi|$ と $|\psi\rangle$ の内積:

ブラケット

$\langle\psi|\psi\rangle = (\alpha^* \quad \beta^*) \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \alpha^* \alpha + \beta^* \beta = |\alpha|^2 + |\beta|^2 = 1$: 数値

量子状態 $|\psi\rangle$ は、 $|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ を正規直交基底とする2次元の複素内積空間内の単位ベクトルで、大きさは1に規格化されている。

\dagger (ダガー) : 随伴行列(エルミート共役)。
転置と要素の複素共役を同時にとる。

例) $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ のとき

$$A^\dagger = \begin{bmatrix} a^* & c^* \\ b^* & d^* \end{bmatrix}$$

ここで

$$a = x + iy$$

$$a^* = x - iy$$

量子カーネルは内積計算で求める

カーネル関数は、特徴量空間のベクトルを引数として受け取り、その内積 $\langle \Phi(x) | \Phi(y) \rangle$ を返します。

- データベクトル： \vec{x}_i
- \vec{x}_i のエンコードとマッピングを行う回路： $\Phi(\vec{x}_i)$

マップされた状態は：

$$|\psi(\vec{x}_i)\rangle = \Phi(\vec{x}_i)|0\rangle^{\otimes N}$$


$$|\psi(\vec{x}_j)\rangle = \Phi(\vec{x}_j)|0\rangle^{\otimes N}$$

その内積は：

$$\langle \psi(\vec{x}_j) | \psi(\vec{x}_i) \rangle = \langle 0 |^{\otimes N} \Phi^\dagger(\vec{x}_j) \Phi(\vec{x}_i) | 0 \rangle^{\otimes N}$$

カーネル行列の要素は、状態 $|0\rangle^{\otimes N}$ を観測する確率：

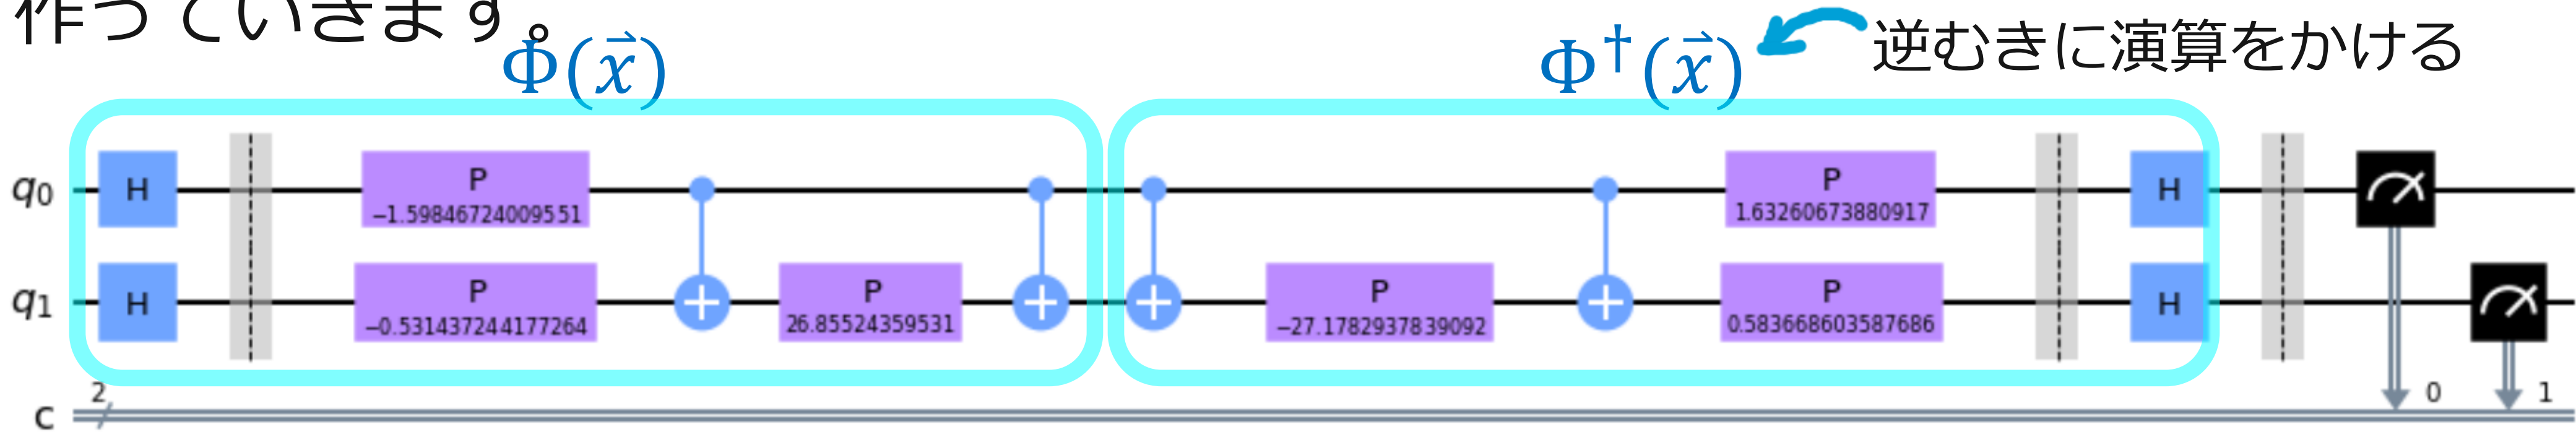
$$P_0 = |\langle 0 |^{\otimes N} \Phi^\dagger(\vec{x}_j) \Phi(\vec{x}_i) | 0 \rangle^{\otimes N}|^2$$



$$P_{|0\rangle} = |\langle 0 | \Phi^\dagger(\vec{x}_i) \Phi(\vec{x}_j) | 0 \rangle|^2$$

量子カーネル


各データ対に対して内積（量子カーネル $\langle \Phi(\vec{x}) | \Phi(\vec{x}) \rangle$ ）を計算、測定してカーネル行列を作っていきます。





1個目のデータと1個目のデータの内積

1個目のデータと2個目のデータの内積

1個目のデータとn個目のデータの内積




n個目のデータとn個目のデータの内積



全く違う特徴：0(白)
同じ特徴：1(濃紺)

量子カーネル


各データ対に対して内積（量子カーネル $\langle \Phi(\vec{x}) | \Phi(\vec{x}) \rangle$ ）を計算、測定してカーネル行列を作っていきます。




今回は、25個の学習データと10個のテストデータに対して、以下を計算します：

- 学習データ同士（例：25x25の行列）
- 学習データとテストデータ(例：25x10の行列)

25x25の行列

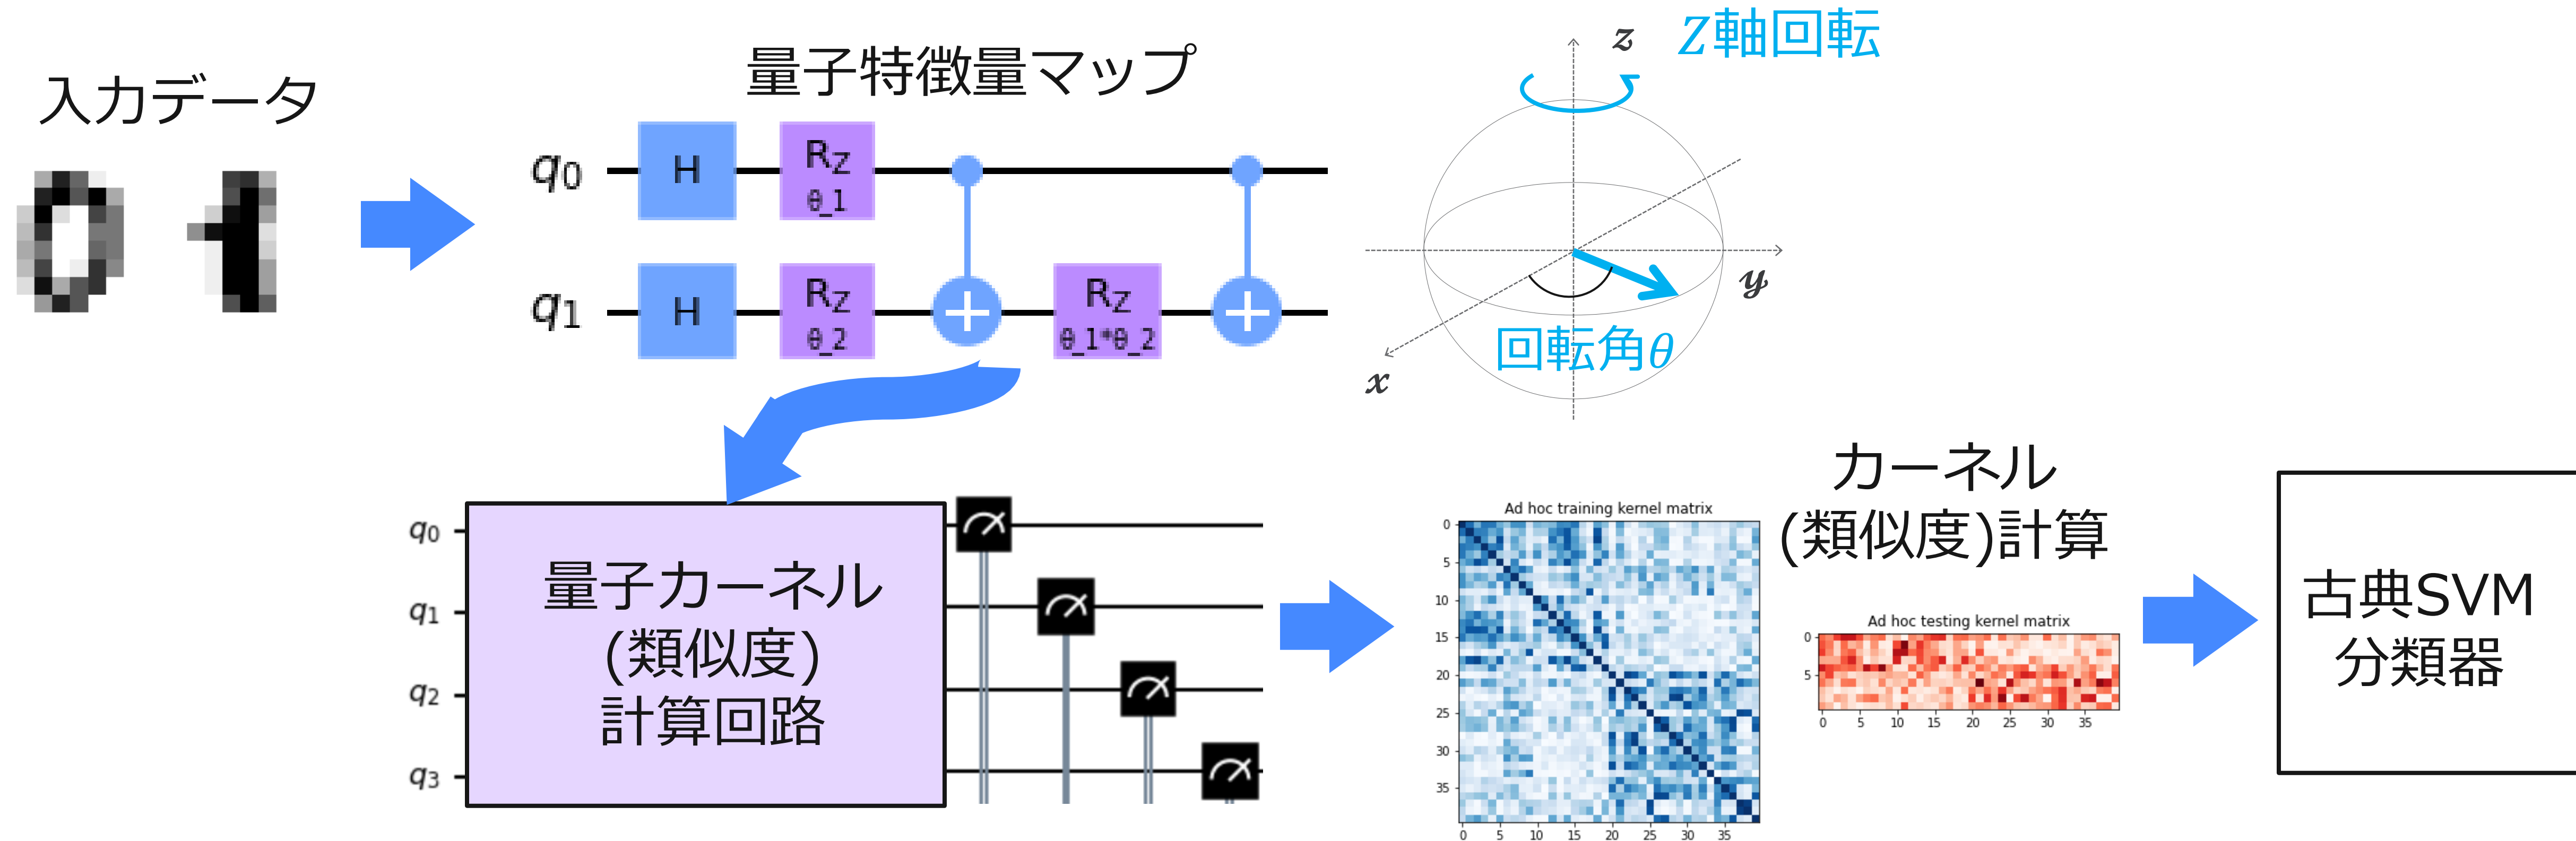


25x10の行列



量子カーネルSVM



データを量子特徴量マップ(Feature Map)でエンコードした後、



量子回路で量子カーネル(類似度)の計算を行い、
量子カーネルを使って、古典SVM計算(線形な境界面で分ける2値分類)で学習・分類を行います。

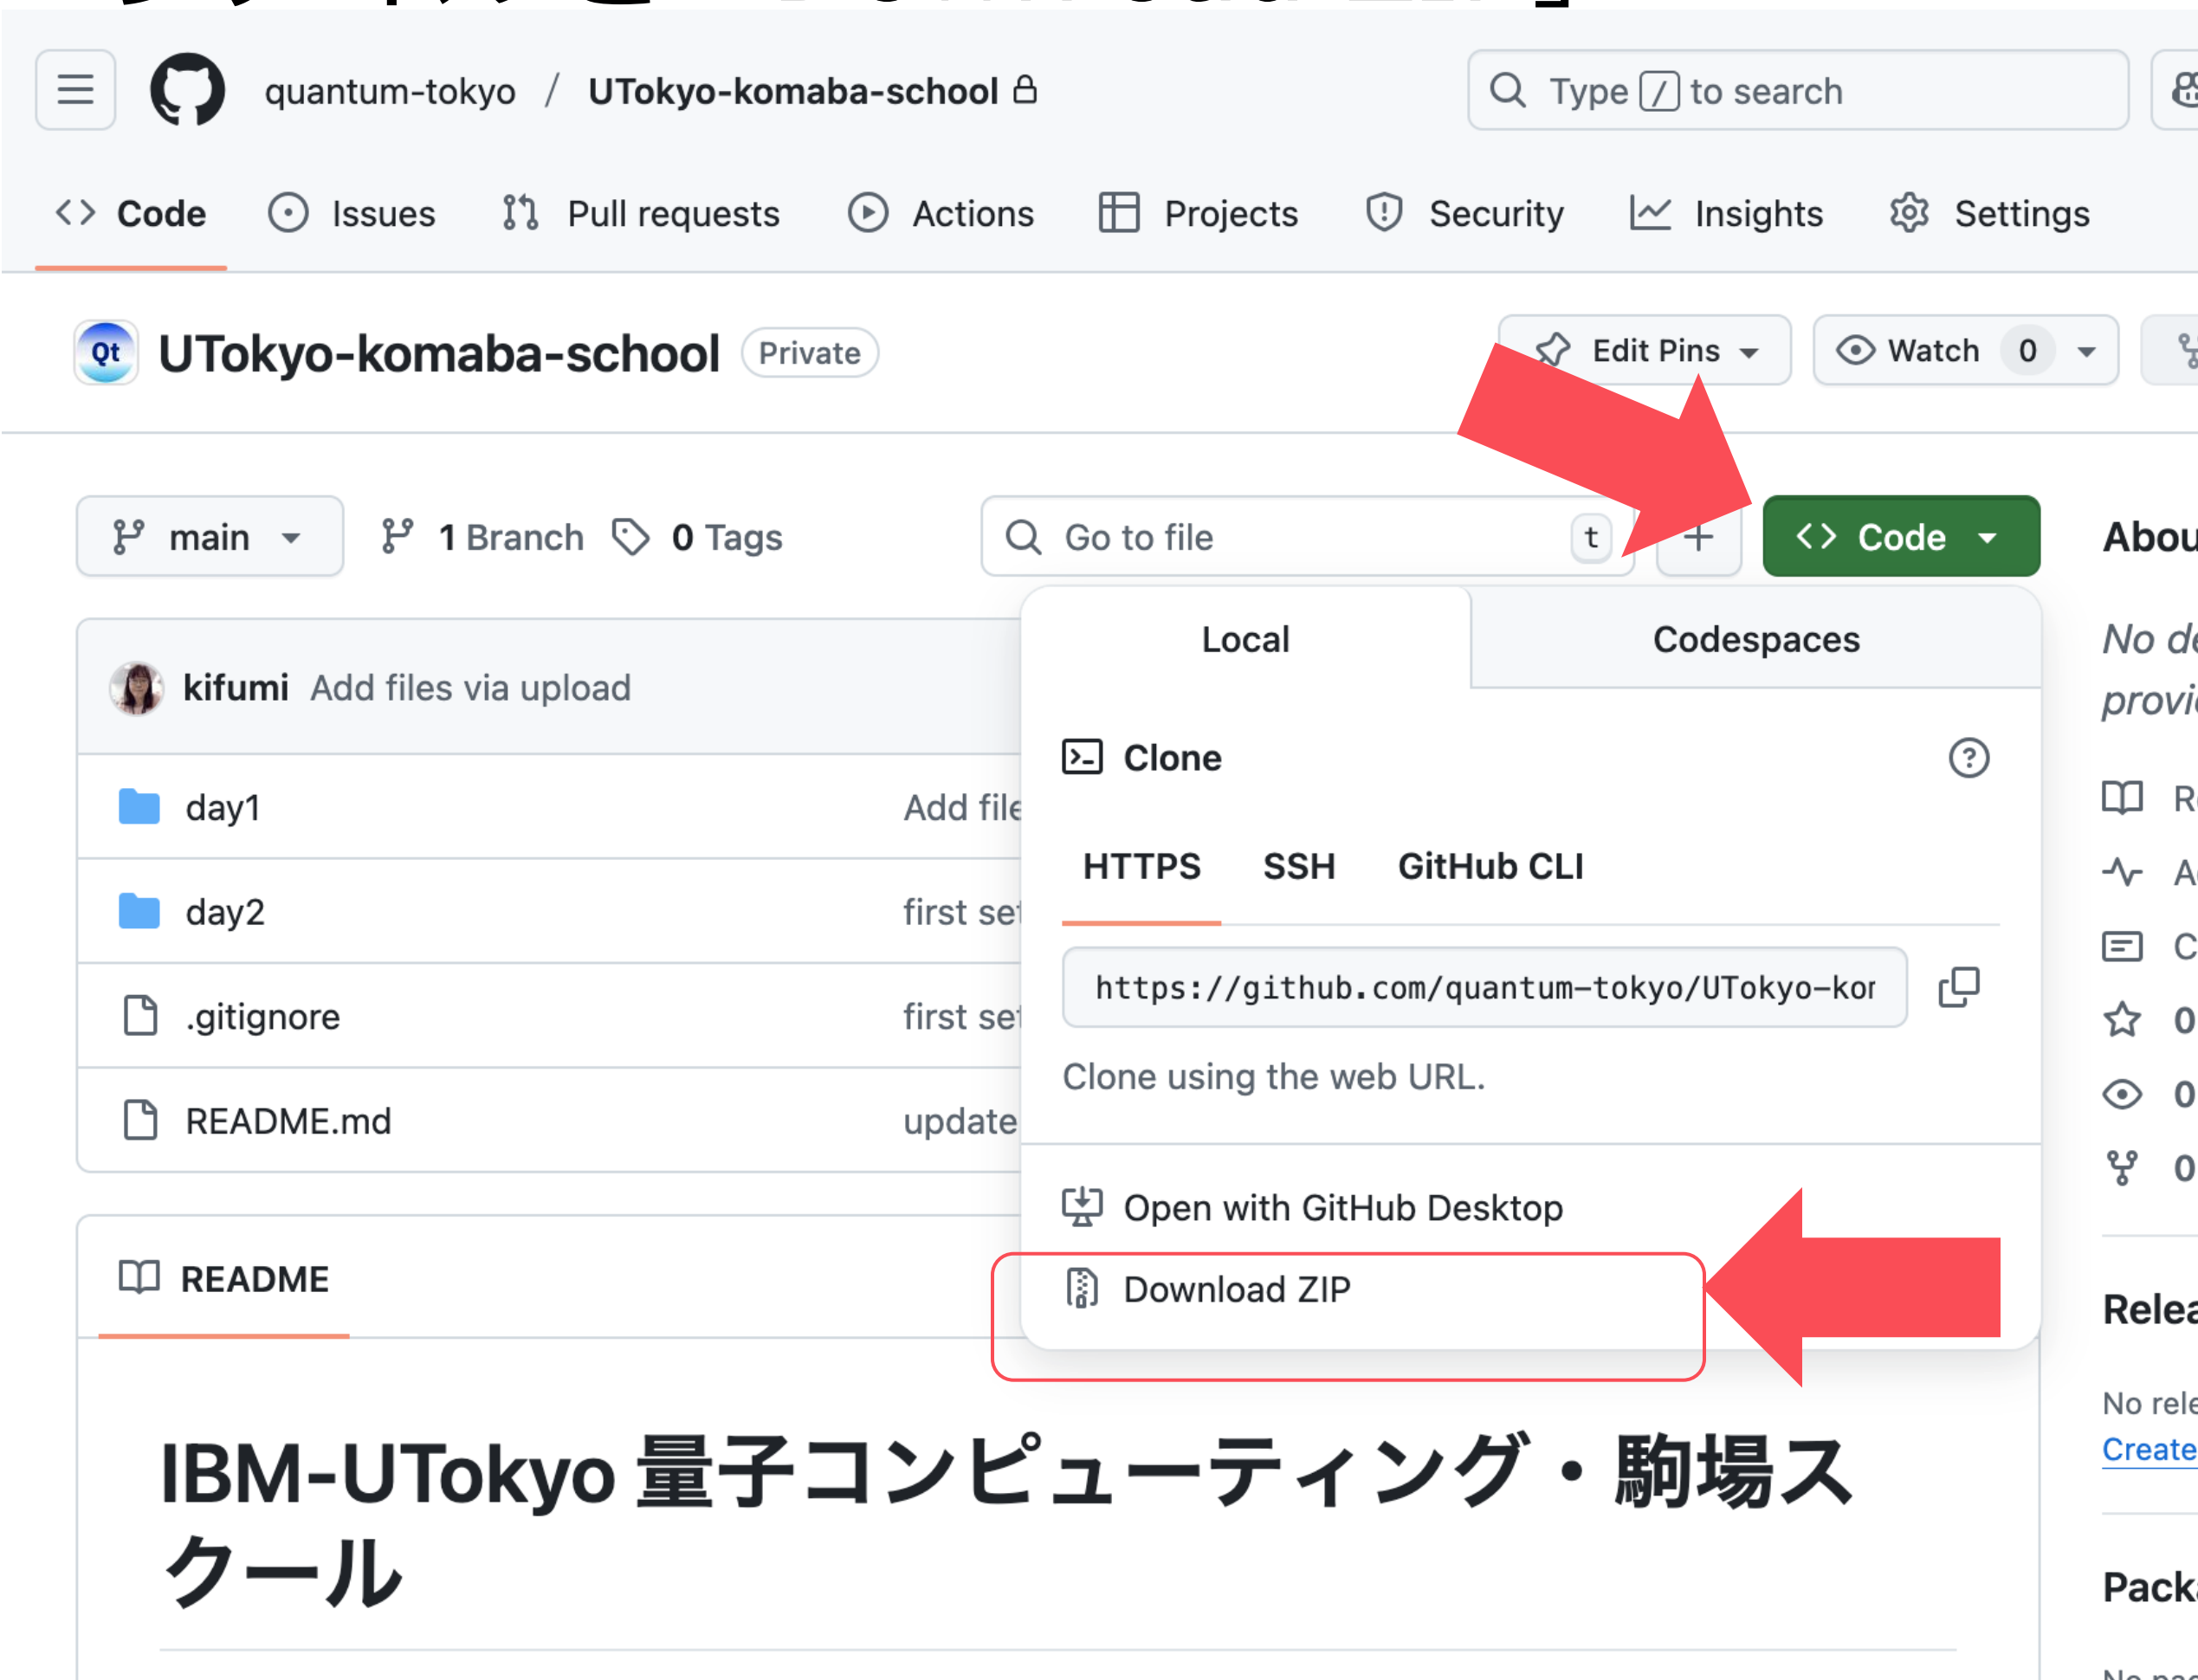
演習

手書き文字(数字)データで量子カーネルを使った機械学習を学んだ後、洋服の画像について、学習分類を行ってみます。



URL: ibm.biz/qkmbgit

(1) 緑色の「Code」をクリックして
ファイルを「Download ZIP」



IBM-UTokyo 量子コンピューティング・駒場ス
クール

(2) Google colabを検索してログイン
<https://colab.research.google.com/>



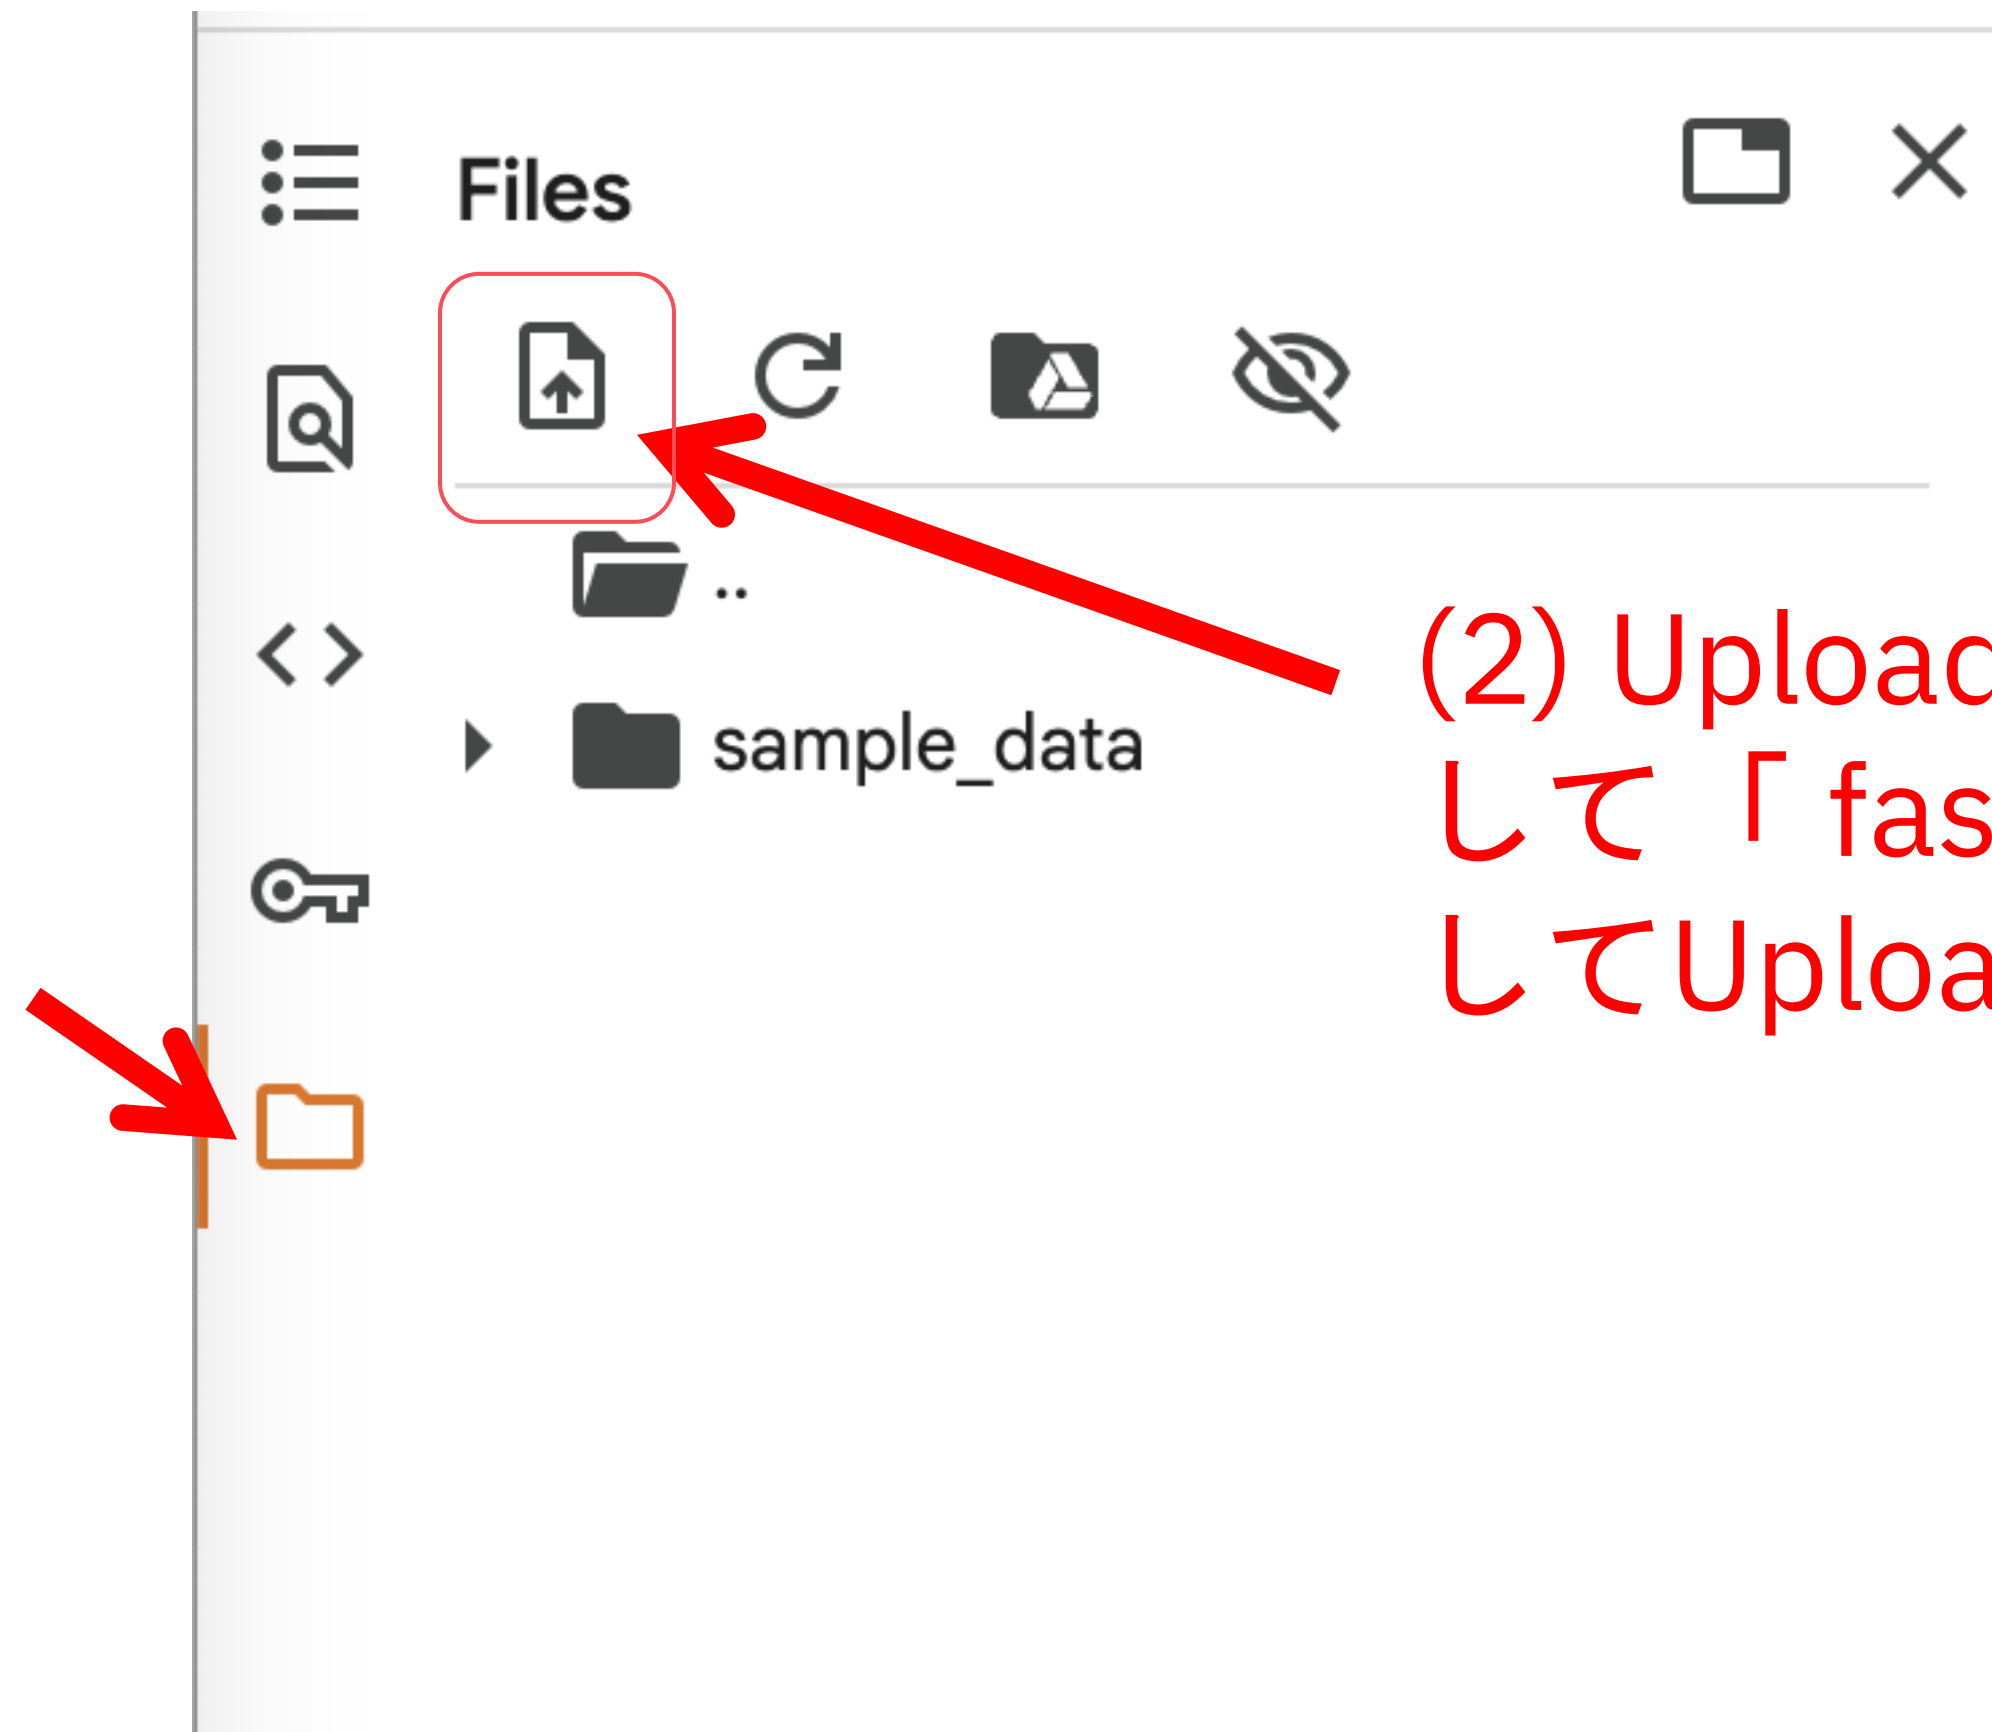
(3) 「ファイル」 →
「ノートブックをアップロード」
で「20250930_6_qml.ipynb」
を選択



20250930_6_qml.ipynb と **fashion.npz** を使います。

以下の手順で **fashion.npz** ファイルもアップロードしてください。



(1) フォルダー
アイコンをクリック



(2) Upload アイコンをクリック
して「fashion.npz」を選択
してUpload



Supervised learning with quantum-enhanced feature spaces

Vojtěch Havlíček, Antonio D. Córcoles , Kristan Temme , Aram W. Harrow, Abhinav Kandala, Jerry M. Chow & Jay M. Gambetta

